王兴路

计算机科学博士　西蒙菲莎大学 (SFU)

(+1)-7783250568 | yanawlx@gmail.com | luzai | xinglu-wang-1734b2116 | Xinglu Wang

教育背景

西蒙菲莎大学　　本那比，不列颠哥伦比亚省

计算机科学，博士　　*2021* 年 *9* 月 - *2026* 年 *4* 月

- 累计 **GPA**: $4.13/4.33$。
- 获得 Helmut and Hugo Eppich 研究生奖学金、研究生助学金、校长研究生入学奖学金。
- 导师：**裴健教授** 与 **王健楠教授**。

浙江大学　　浙江，杭州

信息工程，硕士　　*2018* 年 *9* 月 - *2021* 年 *6* 月

- 累计 **GPA**: $90.75/100$。
- 导师：**李英明教授** 与 **张仲非教授**。

浙江大学　　浙江，杭州

信息工程，学士　　*2014* 年 *9* 月 - *2018* 年 *6* 月

- 累计 **GPA**: $90.21/100$，$3.93/4$，**排名** $7/174$。
- 美国大学生数学建模竞赛 (ICM) **一等奖** (Meritorious Winner)。
- 优秀学生**一等**奖学金。

研究经历

大规模 MoE 推理系统的故障恢复　　*2025* 年 *8* 月 – *2026* 年 *2* 月

科技行业客户，本拿比　　副研究员（实习）

- 为解耦式 MoE 推理系统设计了故障恢复机制，支持注意力和 MoE 计算在独立节点上运行，实现了无需重启实例的快速恢复（成果：*ReviveMoE, ArXiv 2026*）。实现了核心恢复路径，包括注意力和 MoE 执行器的抽象设计，以及用于快速角色转换的 **基于代理的切换**机制。
- 开发了步级（step-level）恢复框架，通过 **基于事务日志**的恢复方式（包含块表恢复、请求迁移和部分重计算），实现了从未知中间状态的安全回滚。

感知 SLO 的 LLM 推理系统　　*2024* 年 *12* 月 – *2025* 年 *8* 月

科技行业客户，本拿比　　副研究员（实习）

- 参与了支持异构延迟目标（服务水平目标, *SLO*）的 LLM 推理系统开发，设计了启发式 **SLO 感知**调度与扩缩容算法，平衡了用户延迟需求与服务成本（成果：*ArXiv 2025*）。
- 深入实践了响应式弹性扩缩容的 **快速扩展**机制，涉及预启动服务进程、设备间权重传输以及解耦模式下的阶段感知编排。

解耦式大语言多模态模型（LMM）推理　　*2024* 年 *2* 月 – *2024* 年 *12* 月

科技行业客户，本拿比　　副研究员（实习）

- 基于 **Encode–Prefill–Decode (EPD)** 解耦架构进行大语言多模态模型推理研究（成果发表于 **ICML 2025**）。负责推理系统的实验评估，分析了不同场景下的执行效率与性能瓶颈。
- 熟悉系统设计细节，包括阶段间协作与 缓存布局设计/管理；应用了对等设备通信（P2P）、**CUDA IPC** 内存共享及 CUDA 虚拟内存管理等底层系统技术。

面向数学建模的大语言模型研究　　*2023* 年 *2* 月 – *2024* 年 *2* 月

科技行业客户，本拿比　　副研究员（实习）

- 利用提示词工程（Prompt Engineering）和监督微调（SFT），评估了 LLM 在处理复杂优化问题时的数学建模能力。在 **EJOR 2025** 合作发表综述，探讨 AI 如何增强优化流水线的各个阶段。
- 针对线性规划应用题，提出了一种基于图编辑距离的评估指标，该指标更符合人类判断，并能有效识别数学等价的表述（成果发表于 **COLING 2024**）。

线性规划的智能初始基选择　　*2022* 年 *2* 月 – *2023* 年 *2* 月

科技行业客户，本拿比　　副研究员（实习）

- 提出一种基于 图神经网络的方法，用于预测线性规划求解器的 **近优**初始基。
- 将模型预测与后处理步骤相结合，为单纯形法热启动生成 有效基。
- 在多个数据集和求解器上验证了该方法相比基于规则的基准方法具有显著的加速效果（成果发表于 **ICML 2023**）。

协同多出口学习

2019 年 *12* 月 – *2021* 年 *8* 月

浙江大学数据科学与工程研究中心 硕士论文

- 研究用于自适应推理的多出口学习，解决了出口之间存在的优化干扰问题。
- 提出使用梯度投影的 梯度去冲突训练方法以解决出口冲突（成果发表于 **IEEE ICIP 2020**）。
- 设计了基于 元学习的 协同加权方案，用于出口间的密集型教师-学生蒸馏（论文被 **AAAI 2021** 接收）。
- 在大规模数据集 ImageNet 上使用 *Cloud TPU* 进行评估；识别并报告了 **pytorch/xla** 中的一个 Bug。

行人重识别

2017 年 *10* 月 – *2018* 年 *6* 月

浙江大学数据科学与工程研究中心 学士论文

- 深入分析了行人重识别全流程（数据采样、特征提取、损失设计、后处理），并总结于 技术博客。
- 开源贡献：(1) 在 **deep-person-reid** 中提出 Cython 模块，将评估速度提升 **20 倍**；(2) 修复了 **pytorch-classification** 中的 ResNet 深度 Bug，确保了 CV 模型的公平比较。

发表论文

[1] Li, H., **Wang, X.**, Feng, C., Zuo, C., Wang, Y., Lo, H., Cui, Y., Wang, B., Cui, D., Jing, S., Shan, Y., Xiong, Y., Wang, J., Zhang, Y., and Fan, Z. 2026. ReviveMoE: Fast recovery for hardware failures in large-scale MoE LLM inference deployments. arXiv preprint arXiv:2602.21140.

[2] Yousefijamarani, Z., **Wang, X.**, Wang, Q., Heisler, M., Shabani, T., Gholipour, N., Yassini, P., Chang, H., Chen, K., Zhang, Q., Bai, X., Wang, J., Xiong, Y., Zhang, Y., and Fan, Z. 2025. HyperFlexis: Joint design of algorithms and systems for multi-SLO serving and fast scaling. arXiv preprint arXiv:2508.15919.

[3] Fan, Z., Ghaddar, B., **Wang, X.**, Xing, L., Zhang, Y., and Zhou, Z. 2025. Artificial intelligence for optimization: Unleashing the potential of parameter generation, model formulation, and solution methods. *European Journal of Operational Research*.

[4] Singh, G., **Wang, X.**, Hu, Y., Yu, T., Xing, L., Jiang, W., Wang, Z., Bai, X., Li, Y., Xiong, Y., Zhang, Y., and Fan, Z. 2025. Efficiently serving large multimodal models using EPD disaggregation. In *Proceedings of the 42nd International Conference on Machine Learning (ICML)*.

[5] Heisler, M., Yousefijamarani, Z., **Wang, X.**, Wang, Q., et al. 2025. LLM inference scheduling: A survey of techniques, frameworks, and trade-offs. *TechRxiv Preprint*. DOI: 10.36227/techrxiv.176238087.79673350.

[6] Xing, L., **Wang, X.**, Feng, Y., Fan, Z., Xiong, J., Guo, Z., Fu, X., Ramamonjison, R., Mostajabdaveh, M., Han, X., Zhou, Z., and Zhang, Y. 2024. Towards human-aligned evaluation for linear programming word problems. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (COLING)* (pp. 16550–16556).

[7] Fan, Z., Huang, F., **Wang, X.**, Zhou, Z., Pei, J., Friedlander, M. P., and Zhang, Y. 2024. Fair and efficient contribution valuation for vertical federated learning. In *Proceedings of the International Conference on Learning Representations (ICLR)*.

[8] Fan, Z., **Wang, X.**, Yakovenko, O., Sivas, A. A., Ren, O., Zhang, Y., and Zhou, Z. 2023. Smart initial basis selection for linear programs. In *Proceedings of the 40th International Conference on Machine Learning (ICML)* (pp. 9650–9664).

[9] Gholami, M., Akbari, M., **Wang, X.**, Kamranian, B., and Zhang, Y. 2023. ETran: Energy-based transferability estimation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)* (pp. 18613–18622).

[10] Qiao, C., Xiang, Z., **Wang, X.**, Chen, S., Fan, Y., and Zhao, X. 2023. Objects matter: Learning object relation graph for robust absolute pose regression. *Neurocomputing*, 521, 11–26.

[11] **Wang, X.**, and Li, Y. 2021. Harmonized dense knowledge distillation training for multi-exit architectures. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(11), 10218–10226.

[12] Ouyang, S., **Wang, X.**, Lyu, K., and Li, Y. 2021. Pseudo-label generation-evaluation framework for cross-domain weakly supervised object detection. In *Proceedings of the IEEE International Conference on Image Processing (ICIP)* (pp. 724–728).

[13] **Wang, X.**, and Li, Y. 2020. Gradient deconfliction-based training for multi-exit architectures. In *Proceedings of the IEEE International Conference on Image Processing (ICIP)* (pp. 1866–1870).